

SEMA – סקירת CTO: מה חסר במערכת

פערים פלטפורמיים, תשתיתיים ומוצריים | יולי 2026

הסקירה מבוססת על מעבר מלא על המערכת: sema_core, שכבת ה-API, שני הפרונטים (Streamlit + React), שכבת הסמנטיקה, ה-evals והתיעוד. קיימת כבר סקירה מוצרית (docs/sema_pm_review.pdf) שמכסה אמון, פרואקטיביות, ייצוא ופידבק – לכן המסמך הזה מתמקד במה שהיא לא מכסה: הפערים שרואים כ-CTO. החפיפה מסוכמת בקצרה בסוף.

פערים מרכזיים (CTO + PM)

1. פאנל ניהול אמיתי – הפער הגדול ביותר

היום יש רק עמוד Streamlit שמחליף client פעיל. חסר Admin Panel (ב-React) שכולל: ניהול לקוחות (הוספה/עריכה/בדיקת חיבור – היום זו עריכה ידנית של clients.yaml), עריכת ה-semantic layer דרך ממשק (היום YAML ידני, בלי ולידציה ובלי versioning), הגדרת התראות, וצפייה בנתוני שימוש.

2. משתמשים, הרשאות ואבטחה

יש מפתח API גלובלי אחד לכל המערכת (SEMA_API_KEY), בלי משתמשים בכלל. חסר: חשבונות משתמש, מפתח פר-tenant, הרשאות תפקיד (אדמין / משתמש / צופה), ו-SSO. בלי זה אי אפשר למכור לאף לקוח – שיחות גם לא משויכות למשתמש, רק ל-client.

3. ניהול היסטוריית שיחות

ה-conversation store קיים בצד השרת, אבל אין אף endpoint לרשימת שיחות – אין ממשק להיסטוריה, חיפוש, שינוי שם או מחיקה. המשתמש מאבד הכול ברענון הדף.

4. דשבורד תפעול ועלויות

obs.py כותב JSON ל-stderr – וזהו. חסר: מעקב טוקנים ועלות פר-tenant, זמני תגובה, שיעור שגיאות, ואילו שאלות נשאלות בפועל (product analytics על המוצר עצמו). קריטי גם לתמחור.

5. Guardrails תפעוליים

rate limiting, אין מכסות פר-tenant, אין תקרת תקציב LLM. לקוח אחד יכול לשרוף את כל חשבון ה-API.

6. התראות – יש מנוע, אין מוצר

מנוע ההתראות רץ רק כשפותחים את האפליקציה (pull). חסר: תזמון אוטומטי (scheduler), ערוצי שליחה (מייל / Slack), היסטוריה ואישור התראה (acknowledge), והגדרה דרך ממשק במקום YAML.

7. חיבור לקוח חדש / דאטה אמיתי

כל הנתונים סינתטיים. חסר: מחברים (Snowflake / BigQuery), ואשף onboarding שמייצר טיוטת semantic layer מתוך introspection של הסכמה. היום כל לקוח חדש פירושו כתיבת YAML ידנית — וזה צוואר הבקבוק לסקייל.

8. קטלוג מטריקות למשתמש

אין דרך לדעת "מה מותר לשאול" — חסר עמוד שמציג את המדדים המוגדרים (Revenue, Loss Ratio וכו') עם ההגדרה העסקית שלהם. גם בונה אמון וגם מוריד שאלות כושלות.

9. תשתית production

SQLite לשיחות (לא ישרוד ריבוי workers), אין migrations, אין CI/CD, וה-evals ידניים ולא רצים אוטומטית על כל שינוי פרומפט. וכ-CTO: שני פרונטים במקביל הם מס תחזוקה כפול — הסקירה המוצרית כבר ממליצה להקפיא את Streamlit, ואני מסכים.

חפיפה עם הסקירה המוצרית הקיימת (בקצרה)

הסבר "איך חושב המספר" בשפה עסקית + שדה ה-confidence שכבר קיים בחוזה ה-API ואינו בשימוש; סיכום שבועי אוטומטי במייל; יעדים וזיכרון עסקי; ייצוא ושיתוף תשובות; ופידבק "מועיל / לא מועיל" שמזין את מערך ה-evals.

סדר עדיפויות מוצע

אבטחה ומשתמשים (2) ← פאנל ניהול (1) ← היסטוריית שיחות (3) ← עלויות ומכסות (4+5) ← התראות כמוצר (6) ← onboarding ודאטה אמיתי (7). קטלוג המטריקות (8) ותשתית ה-production (9) משתלבים לאורך הדרך; השאר — לרבעון הבא.